Agent Trace： 数据管理与应用

记录形态、存储管理与 VISTA 实例

记录形态 → 存储管理 → VISTA 应用

曹金羽 · Agent Trace 组

2026-11-09

Trace 回顾： span 树与时间轴

span （缩进与连线 = 父子层级）	时间 → ◆ span 内事件 红色 = ERROR	结果与内容
L0 agent 修复测试 fix-42		任务通过（任务层验证）
L1 LLM chat： 分析失败		输入 / 输出 tokens
L1 retriever 检索相关经验		命中 1 条 memory
L1 agent 子 agent： 复现问题		独立子任务
L2 LLM chat： 制定复现步骤		测试命令
L2 tool run_tests		ERROR • exit 1
L1 LLM chat： 生成修改		修改依据与输出
L1 guardrail 检查修改范围		通过
L1 tool edit_file date.py		文件与 diff
L1 tool run_tests （重测）		OK · exit 0
L1 evaluator 评估测试结果		通过

对话文本

消息数组 • Chat Completions 格式

```
[
 {"role": "user",
  "content": "test_parse_date 一直失败，帮我修一下"},
 {"role": "assistant",
  "content": "先运行这个测试，确认失败信息。",
  "tool_calls": [{"id": "call_7",
    "function": {"name": "run_tests",
                 "arguments": "{\"k\": \"parse_date\"}"}}]},
 {"role": "tool", "tool_call_id": "call_7",
  "content": "1 failed: test_parse_date (exit 1)"}
]
```

State

checkpoint 快照 • LangGraph 形式，字段有简化

```
{"thread_id": "fix-42", "step": 6, "next": ["edit_file"],
 "values": {"failing": ["test_parse_date"], "edited": []}}
{"thread_id": "fix-42", "step": 9, "next": [],
 "values": {"failing": [], "edited": ["date.py"]}}
```

Memory

经验条目 • 纯文本，带来源

1. parse_date 相关测试失败时，先检查测试是否固定了 TZ。
   来源： span a3c1 · 版本 1
2. 本仓库运行单个测试： pytest -k < 名称 > 。
3. 改动 date.py 后，同时重跑 test_parse_date 与 test_format_date 。

Trace

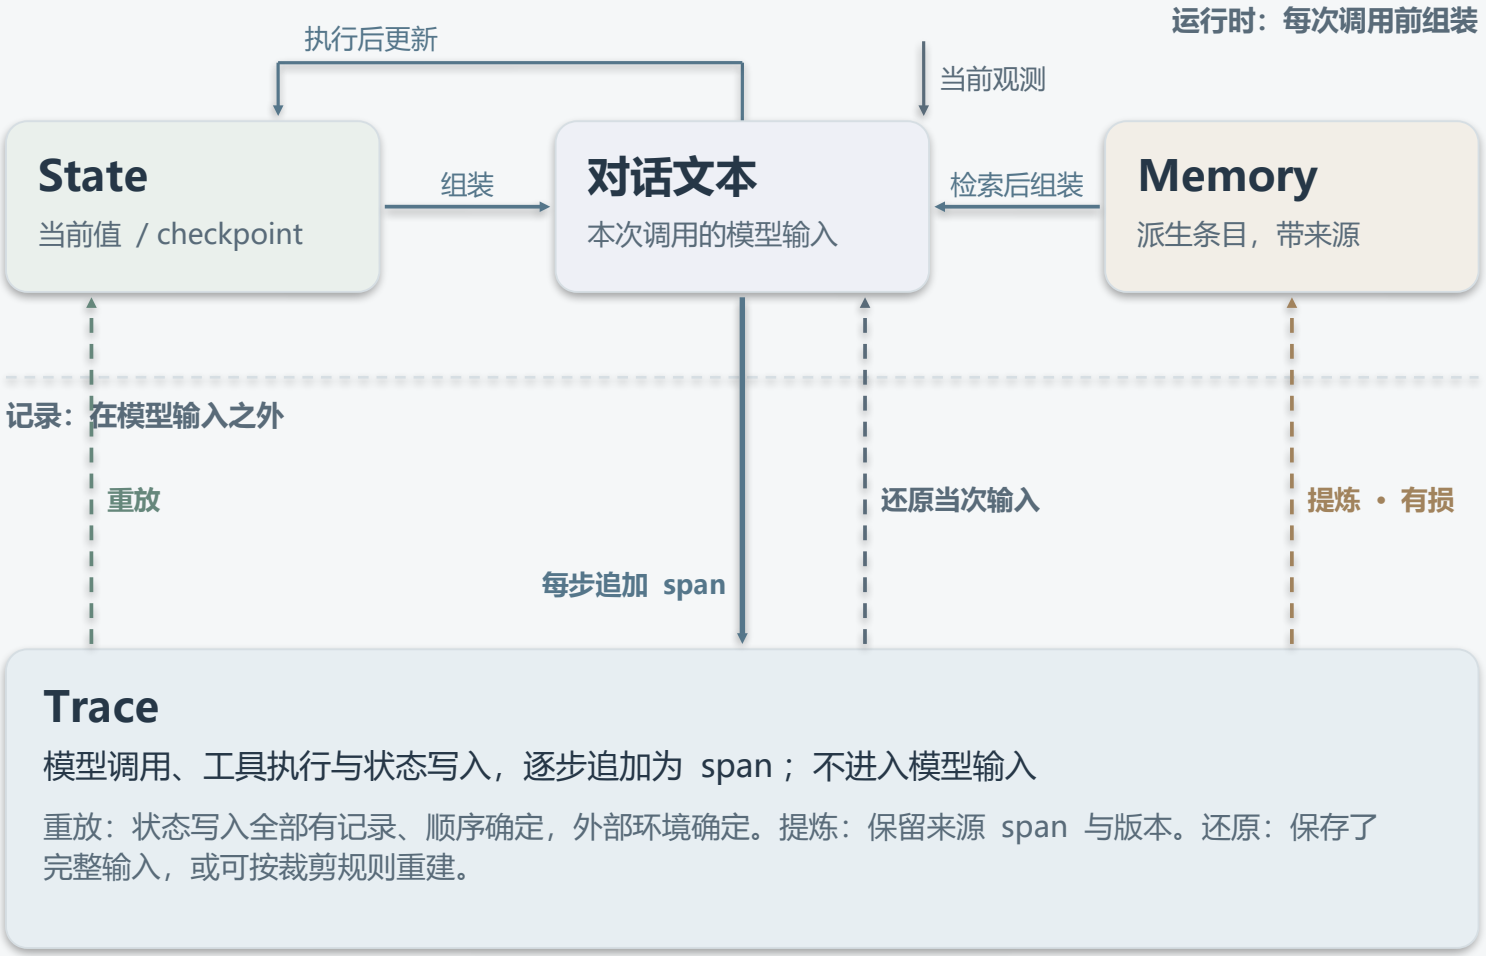
span 树 • 按 parent_span_id 组装后的视图

```
{"trace_id": "4bf92f35…", "span_id": "7d00",
 "name": "invoke_agent fixer",
 "time": "+0.0s → +100.0s", "status": "OK",
 "children": [
  {"span_id": "7d01", "name": "chat model-a",
   "attributes": {
     "gen_ai.usage.input_tokens": 3120}},
  {"span_id": "7d02",
   "name": "invoke_agent reproducer",
   "time": "+14.0s → +45.0s",
   "children": [
    {"span_id": "a3c1",
     "name": "execute_tool run_tests",
     "time": "+22.0s → +43.1s",
     "status": {"code": "ERROR", "message": "1 failed"},
     "attributes": {
       "gen_ai.tool.call.id": "call_7",
       "process.exit.code": 1},
     "events": [{"name": "exception",
                 "time": "+43.0s"}]}]},
  {"…": "检索、生成修改、检查、编辑等 5 个 span"},
  {"span_id": "7d09",
   "name": "execute_tool run_tests",
   "status": "OK"}]}
```

对话文本、 Trace 、 State 与 Memory： 内容与格式

	对话文本	Trace	State	Memory
记录对象	本次发给模型的 消息与工具结果	每次操作、关系 与结果	当前进度、变量 与待办	跨任务复用的 规则、事实与偏好
典型格式	消息数组 role · content	span 树 ID · 父关系 · 时间	快照或键值 按线程与步骤保存	条目 + 来源 按命名空间检索
写入方式	追加；可裁剪、 压缩、改写	只追加	覆盖当前值 或新增快照	提炼、修订、撤回
时间范围	一次调用的窗口	整个执行过程	某一时刻	跨会话、跨任务
主要读取方	模型、用户	开发、评估、 归因、审计	框架：继续、 恢复执行	后续任务中的模型
DB 类比	一次查询的结果集	日志 / WAL	数据页 / 调用栈	物化视图 / 索引

重叠、互斥与转化：运行时组装与事后派生



重叠

第 3 页 call_7 的结果同时出现在对话文本的 tool 消息、 trace 的 span 和 memory 的来源中。

只在一处

span 关系、时延、重试、被裁剪的旧消息、state 覆盖前的旧值只在 trace 中； memory 的归纳结论在 trace 中没有逐字原文。

还原输入的代价

同批 Open-SWE 样本：每次调用存完整上下文，比只存新增消息大 53.15 倍；增量存储需按裁剪规则重建。

Trace 存什么：按 GenAI 约定存储的 span

一条 span 的存储形态（每个 span 一条记录）

```
{"trace_id": "4bf92f35…",
 "span_id": "7d01", "parent_span_id": "7d00",
 "name": "chat model-a",
 "start_time": "+0.0s", "end_time": "+8.0s",
 "status": {"code": "OK"}, "kind": "CLIENT",
 "attributes": {
   "gen_ai.operation.name": "chat",
   "gen_ai.request.model": "model-a",
   "gen_ai.usage.input_tokens": 3120,
   "gen_ai.input.messages": [
     {"role": "user",
      "parts": [{"type": "text",
                 "content": "帮我修复失败测试"}]}]},
 "resource": {"service.name": "fixer-agent"},
 "events": [], "links": []}
```

user 消息属于右侧④。模型调用有输入；把消息正文写入 Trace 需显式开启。工具等其他 span 可不含消息。

① 结构与时间

必有

trace_id · span_id · parent_span_id （根 span 无） · name · 起止时间

归组、标识、连成树、排出时间轴；缺一项则树或时间轴无法拼出

② 结果与类型

有默认值

status （默认 Unset ） · span kind （默认 INTERNAL ） · gen_ai.operation.name

筛选失败；区分模型调用、工具执行与 agent

③ 上下文与度量

可选，体积小

resource · 运行 ID · 模型、工具、 agent 名 · token 用量 · 配置版本

比较配置、统计成本、跨 trace 关联

④ 内容与关联

可选，体积大或稀疏

输入输出消息 · 工具参数与结果 · 文件与截图 · events · links · 评分 · 采集标记（采样、截断、脱敏）

复现决策、审计、评估与训练；内容在约定中默认不采集

Trace 怎么存：字段特性决定存法

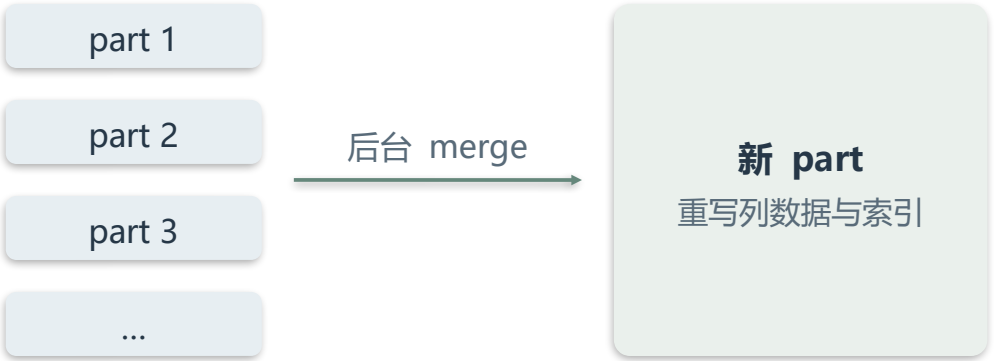
字段组	必有性	体积与取值	写后变化	主要读取	常见存法
结构与时间	必有	定长 ID 、时间戳	写后不变 可能重复、乱序 或缺父 span	按 trace_id 取树 按时间范围扫描	普通列； ID / 时间 作排序或分区键 parent 不设外键
结果与类型	有默认值	枚举，低基数	span 结束时确定	过滤失败 按类型聚合	普通列或字典编码
上下文与度量	可选	值小，键集合 随工具、模型增加	写后不变	看板过滤与聚合	常用键提为普通列 其余用 JSON / 子列 表示实验见第 10 页
反馈与派生	可选 晚到	值小，可带版本	运行后追加或修订	评估、选样	独立表，带版本 按 trace / span ID 关联
内容	可选 显式开启	单条消息中位 130 B 累积输入中位 98 KB	写后不变 脱敏或到期删除	列表不读；详情按 ID 回放、导出批量读	布局见第 11 页 长载荷实验

三个引擎：与实验相关的存储特性

	openGauss 行存 · x86	XStore 行存 · ARM	ClickHouse 列存 · x86 / ARM
存储模型	PG 系 heap 页，一行为一个 tuple	GaussDB 系 heap 页 SQL 与 openGauss 同源	MergeTree：写入生成 part 后台 merge 合并（见下页）
大字段	超过约 2 KiB 时压缩另存 主行只留 TOAST 指针	不使用 TOAST 大字段不压缩，留在主表 heap	按列存放并压缩 查询只读用到的列
JSON	JSON 存文本 JSONB 存二进制文档	本轮未测	JSON 类型按路径拆成子列 机制见下页
实验涉及	B-tree 索引 表达式索引与 GIN 索引	空字符串按 NULL 处理 不支持 FILTER 聚合 分页游标需补时间下界	part 数影响查询速度 无行级更新，改用 mutation JOIN 先读整张右表

ClickHouse： part 与 merge、JSON 子列

MergeTree： part 与后台 merge



- 每次 INSERT 生成一个不可变的 part，各列分别压缩存放
- merge 把相邻小 part 合成新 part，再原子替换旧 part
- 查询逐个打开 part， part 越多定位开销越大
- 没有行级更新，改一行要用 mutation 重写所在 part

JSON 类型：按路径拆成子列



- 按路径查询只读对应子列，不解析整段文本
- 每个 part 各自分配路径， merge 时按非空值数重选
- 返回完整文档要汇集全部子列再重组
- 子列与路径元数据增加写入工作和空间

JSON 表示实验：按查询形态选择表示

PG JSON
文本存储；读取路径时解析

PG JSONB
写入时解析；按二进制结构定位

ClickHouse JSON
同名路径跨行组织为子列（第 9 页）

同一输入： JSON 保存原文， JSONB 保存解析后的文档结构

```
{"b": 2, "a": 1, "b": 3}
```

JSON： 校验语法，保留空格、键顺序与重复键；
按路径取值时重新解析文本。

JSONB： 识别对象与数值 → 键排序、重复键保留末值
逻辑结果为 {"a": 1, "b": 3}，再序列化为连续字节。

[总长度][对象头： 2 对][JEntry × 4][数据区]

JEntry： 类型 + 结束位置；数据区： a 、 Numeric(1) 、 b 、 Numeric(3)

openGauss 6.0 结构示意；嵌套对象递归存放，数组保留顺序。

实验 openGauss JSON 与 JSONB · ClickHouse String 与 JSON · 同一 x86 主机 · 48,534 个 span · 按 truth 核对 · 三轮 p50

写入与空间

文本更省

ClickHouse 总空间

JSON 类型	String	更优
54 MiB	**33 MiB**	

路径过滤与聚合

结构化快 3–12 倍

ClickHouse 高密度过滤

String	JSON 类型	更优
81 ms	**9.9 ms**	

返回完整文档

文本更快

openGauss 带总数分页

JSONB	JSON	更优
458 ms	**193 ms**	

长载荷布局实验：四种布局

same_table

events
普通列 + 载荷

列表与详情
都读同一张表

separate

events_analytics
普通列

event_payloads
event_id + 载荷

详情与 Trace
按 event_id 连接两表

full_core

events_full
普通列 + 载荷

events_core
普通列副本

写入时双写
列表读副本，详情读完整表

asset_ref

events_analytics
普通列 + asset_id

assets
每个对象一行：状态与校验值

对象文件
库外，按内容寻址

库内两张表
读取时核对目录与文件

含载荷的表　不含载荷的表　库外文件（虚线以下）

载荷　160 条，占 0.33% 的行 · 三档 64 KiB / 512 KiB / 2 MiB · 等总字节对照 80 MiB = 40 × 2 MiB 或 1,280 × 64 KiB

场景　写入与空间 · 列表与预览 · 单条详情与完整 Trace · 批量恢复 · 并发 · ClickHouse part 状态

核对　四种布局返回相同的行与载荷字节 · 逐条核对 SHA-256 · 四轮 p50

长载荷布局实验：各场景的推荐布局

场景	openGauss	XStore	ClickHouse
写入	same_table	same_table	same_table
总空间	same_table	asset_ref	same_table
列表与预览	四种相同	避开 same_table	same_table
详情与 Trace	库内布局	库内布局	避开 separate
大对象批量恢复	asset_ref	asset_ref	asset_ref
小对象批量恢复	库内布局	库内布局	库内布局

外置后的总空间

openGauss	**2.88 倍**
XStore	**0.79 倍**
ClickHouse	**6.92 倍**

asset_ref 相对 same_table

批量恢复 80 MiB

40 × 2 MiB	**外置最快**
1,280 × 64 KiB	**外置最慢**

取决于对象数，与总字节无关

ClickHouse 的 part 状态对列表的影响约为布局差异的 3 倍，先控制 part 数

选型推论：按引擎与访问需求

引擎	长载荷布局	动态属性	维护
openGauss	same_table	JSONB	列表与 Trace 复合 B-tree
XStore	full_core	待测	分页游标补时间下界
ClickHouse	same_table 分层时用 full_core	JSON 类型	控制 part 数

看板与列表为主

列存 + 库内布局

例如 Langfuse 另建列表表

运行中读回刚写入的历史

行存 + 库内布局

例如第 20 页的 VISTA

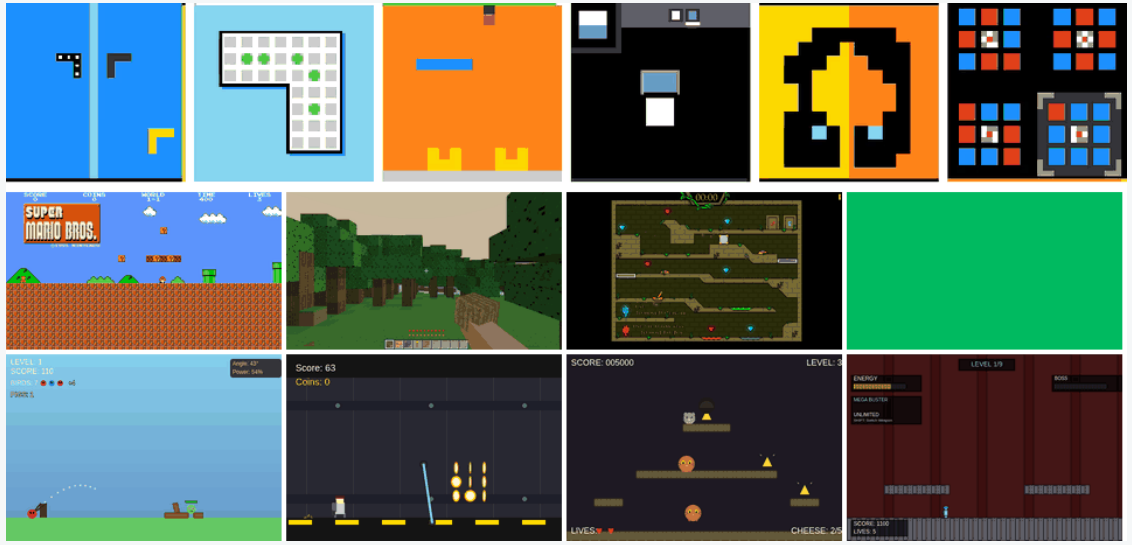
频繁导出 MiB 级对象

外置引用

读取时核对对象字节

建表之前先定记录约定：完整上下文与增量相差 53 倍 · 签名与精确重放另存原文 bytes

ARC-AGI-3： 定位、规模与计分



VISTA 原始多场景动图；放映时播放

游戏形态

64×64 网格、 16 色画面；按键、撤销与点击动作。不给规则与目标，需要探索、推断胜利条件，并把规律迁移到后续关卡。人类可解全部环境。

定位

ARC Prize 推出的第三代 ARC-AGI，官方定位为首个交互式推理 benchmark；衡量在陌生环境中探索、建模和持续学习的效率。 2026 年 3 月发布时前沿模型均低于 1%。

规模与竞赛

公开 25 个游戏、 183 关；半私有、完全私有各 55 个。 ARC Prize 2026 设 ARC-AGI-3 赛道，经 Kaggle 离线评测，总奖金 85 万美元，大奖要求 100% 并开源。

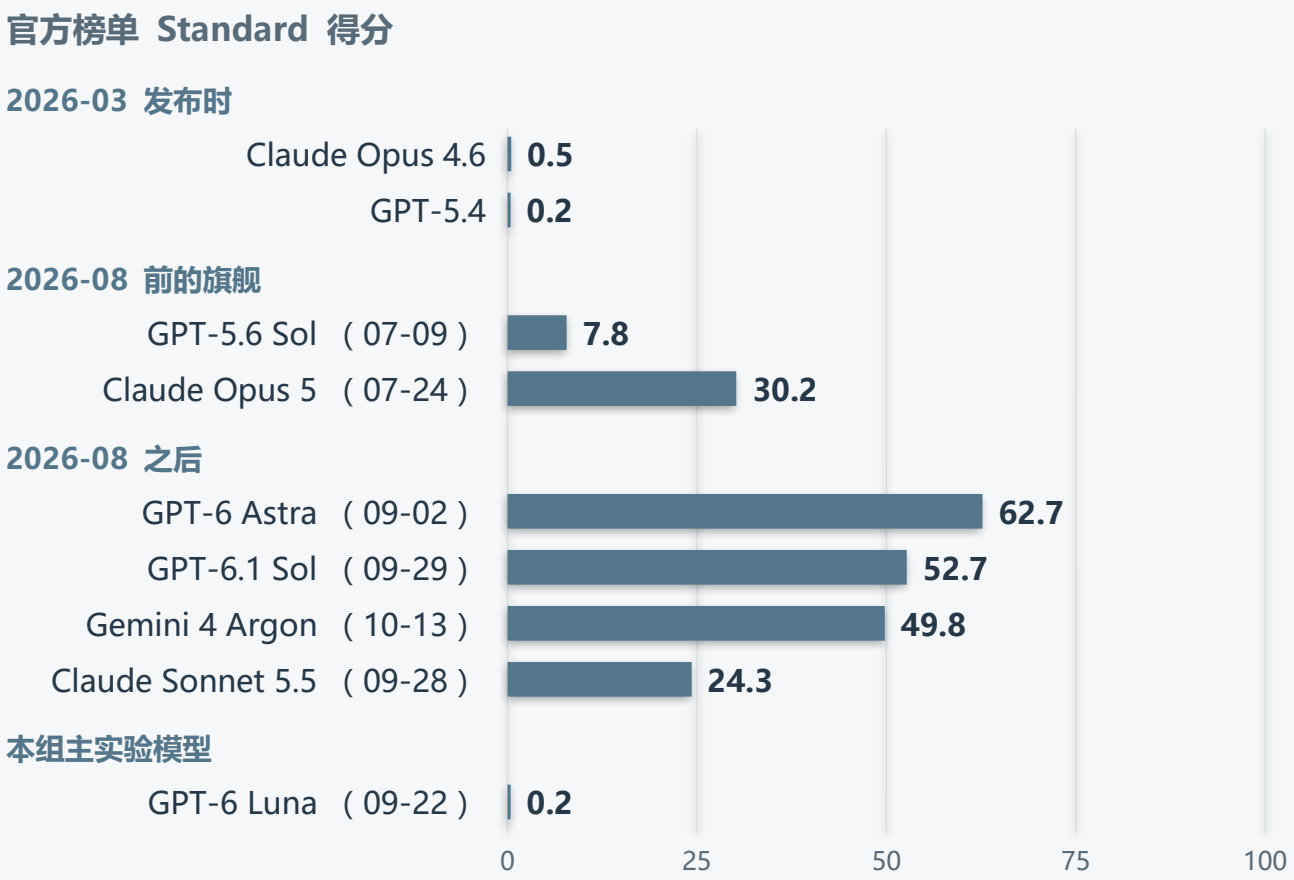
计分： RHAE

游戏与关卡难度不同，以首次游玩者的动作数为基线，衡量过关与动作效率；只计改变环境的动作，后续关卡权重更高，各游戏等权汇总。

官方测试

官方榜单用半私有集，统一系统提示，不提供工具和 harness；每关动作上限为人类中位数的 5 倍。 harness 结果另列社区榜单。

ARC-AGI-3 得分：官方榜单与 harness



VISTA 论文：公开 25 个游戏， RHAE

Claude Opus 5.0

40.68 → 100.00

基线由官方公开集逐局得分计算

GPT-5.6 Sol

13.33 → 99.00

基线为同模型最小 harness

两者在 VISTA 下通关全部 25 个游戏。本组 Luna 结果见第 24 页。

两组数字不能直接比较：官方榜单为半私有集、无工具；论文与本组实验为公开集、带 harness， effort 与每局动作上限另有设定（论文 2,000 动作）。

官网人类试玩：ls20 →

VISTA： 无损视觉记录与 8 个工具

VISTA （Qiushi Han 、 Kaiming He 等， 2026）是 ARC-AGI-3 上的执行框架：每帧画面无损保存并整局保留，模型用工具按回合号取回任意历史画面与动作记录，并维护两份笔记。

类别	工具	输入	返回
行动	play	ACTION1–7 或 RESET ； 点击带坐标	元数据 + 本回合最后一帧
查看	inspect	1–16 个视图：回合、帧、区域	放大后的历史截图
	read_pixels	1–64 个视图，按网格采样	颜色符号矩阵
查历史	history	events 或 attempts ，可限回合区间	逐回合动作与结果；各次尝试概况
长期笔记	read_guide / write_guide	全文读写，至多 64 KB	整局保留的游戏理解
本关草稿	read_working / write_working	全文读写，至多 16 KB	过关时归档并清空

系统提示共 9 行：要求用尽量少的动作完成游戏，维护可修订的游戏理解，行动前说明预期、行动后说明变化。不提供规则与策略；内置工具全部禁用，模型不能读文件或执行代码。只有 play 自动返回画面，其余历史需按回合号主动查询。

上下文会压缩，历史和笔记继续保留

会话 k

当前上下文
模型调用与工具返回

→

检查点

更新 WORKING
保留已有理解与下一步

→

会话 k+1

当前观测 + 笔记
需要时再检索历史

整局保留的记录

截图与动作记录

GUIDE： 较稳定理解

WORKING： 当前状态

VISTA 的三层：上游能力、 trace 接入、经验辅助

层次	保存与提供什么	读取方与语义
上游 VISTA **工具、观测与笔记**	play / inspect / history 等工具 截图与动作文件； GUIDE / WORKING	模型运行中按需读取 上下文压缩后靠笔记和工具继续
本地扩展 • trace 接入 **统一记录与恢复**	动作、观测、模型与工具调用、笔记版本 同一局写成一个 trace OTel 采集，写入 PostgreSQL	游戏读取：写后可读 审计记录：结束时核对 恢复：读取已确认前缀
本地扩展 • 11 项 aids **经验的整理与使用**	框架整理观测、检索和尝试统计 模型编写规则与交接 reset 提供操作入口	提示进入下一次模型输入 规则由模型编写 框架保存来源与修订

VISTA Trace 版：写入与读取路径

VISTA 控制器

动作、截图、笔记

→

OTel / OTLP

游戏与审计通道

→

Collector

exporter 适配

→

PostgreSQL

events + 读取索引

读取适配层

历史截图

动作顺序

笔记版本

读屏障与恢复：从已确认的记录继续

读屏障：工具返回历史前，确认本局相关记录已可读

① 追加记录
已结束的即时 span；记下待确认 span_id

→

② 推进导出
force_flush 游戏数据通道

→

③ 确认入库
查询待确认 ID，齐全后允许读取

读取结果按 agent.seq 恢复顺序 • 按 span_id 去重 • 超时明确报错

恢复：从已确认的动作继续同一局

选择断点
源运行与确认步

→

读取状态
动作前缀 + 笔记版本

→

重放校验
逐步比较观测

→

继续执行
新会话与来源标记

恢复点 = 运行 ID + 确认动作序号 + 对应笔记版本 + 恢复来源

读屏障只等待游戏数据通道的即时记录； play 返回的最后一帧来自本次渲染。恢复要求环境确定、配置一致，新运行延续动作计数与剩余预算。

11 项 aids：把执行历史整理成决策提示

类别	辅助	对执行历史或当前观测的使用
观测解码	diff · geometry click · layout	比较动作前后画面；说明网格坐标；回显点中对象；新关列出对象并提示保存上一关解法
检索、统计与停滞	repeat · coverage attempt · stall	检索相似局面的已试动作与结局；统计点击覆盖、尝试预算与结果条件；画面停滞时要求更新笔记
记忆与交接	mechanisms handoff	记录、修订、撤回带证据回合的规则；交接写明局面、模型、已试、计划与未决问题
操作入口	reset	本关已有动作时允许重开，用于重新验证假设

repeat 、 coverage 和 attempt 统计由确定性代码维护；机制规则由模型编写，框架保存证据、版本与修订。辅助使用运行中可见的信息，游戏源码用于事后核验。得分对应 11 项组合，单项贡献需要消融。

tu93： 同局历史进入下一次决策



历史运行回放 · Luna 全开组 tu93 · T145–156 · 29.52 秒，等待时间已压缩

T155

引用本局 T98 的尝试结果

笔记

模型记录已试路线与不同出口

T156

执行向下动作，并记录新的观察

经验辅助的提升：过关、效率与跨关复用

游戏或关卡	VISTA trace	VISTA + aids	变化
tr87 整局	5/6 关 · 2,000 动作	6/6 关 · 219 动作	新增通关， 56.00 → 100.00
cd82 整局	6/6 关 · 275 动作	6/6 关 · 183 动作	同样通关， 50.93 → 85.83
vc33 整局	1/7 关	6/7 关	多过 5 关， 0.01 → 27.99
tn36 整局	1/7 关	3/7 关	多过 2 关， 0.05 → 19.86
tu93 整局	5/9 关 · 2,000 动作	9/9 关 · 927 动作	新增通关
sb26 第 7 关	645 动作	37 动作	人类基线 58
lp85 第 4 关	205 动作	24 动作	复用第 3 关规则
s5i5 第 3 关	506 动作	90 动作	利用中间帧与历史反馈

sc25 • 成功条件跨关使用

第 4 关 T386 结果与最后方向关联，写入 GUIDE；第 5 关 T893 修订条目；第 6 关 T1101 主动按左。第 5 关 904 → 452 动作，第 6 关 211 动作通过。

lp85 • 历史提示选择新控件

T761 依据 repeat 中“同一局面尚未试过 LC” 选择该控件；第 3 关的共享路口规则用于第 4 关。

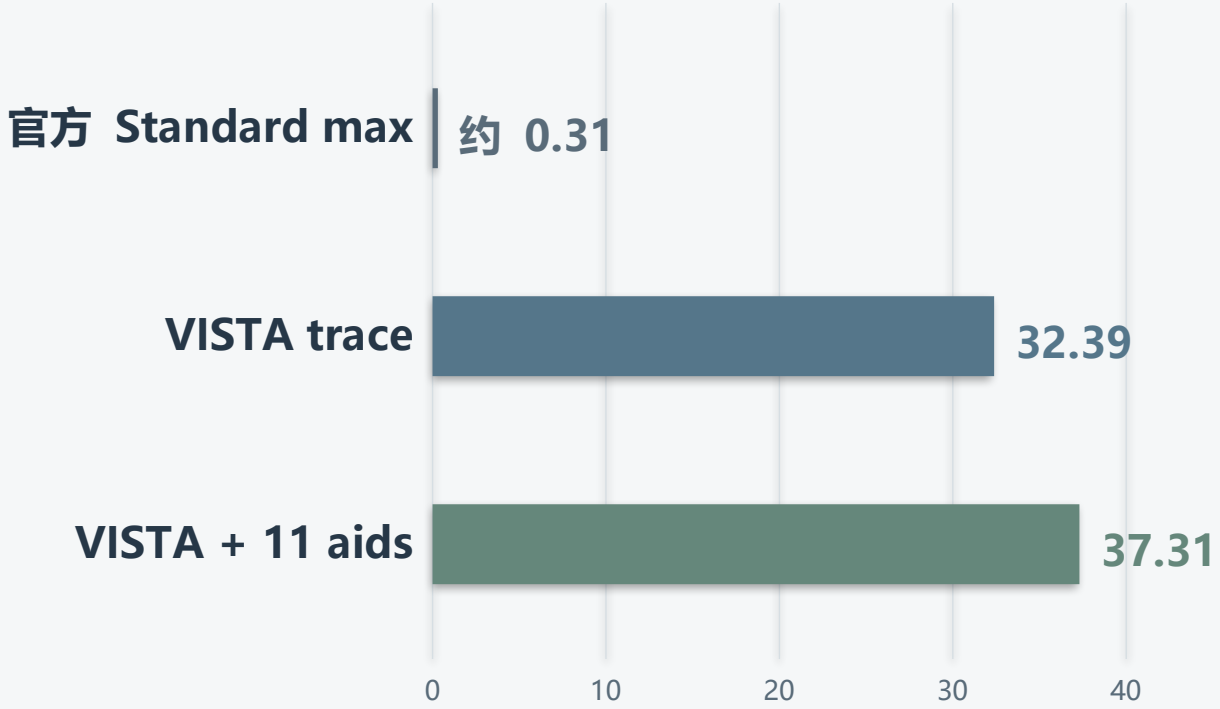
s5i5 • 比较历史反馈

T1993 比较“ yellow-right 11 次无效”与“blue-right 8 次产生变化”，选择后者；中间帧用于识别碰撞回滚。

Luna 25 游戏全量，每组每游戏一局、 2,000 动作。表中为整组配置差异；右侧为模型引用历史提示或笔记的记录，单项贡献需要消融。

Luna： 完整框架与经验辅助的整体效果

25 游戏平均 RHAE （0–100 分；条长按 0–40 真实比例）



配置	过关 /183	通关 /25	总动作
官方	未公布	未公布	未公布
trace 组	108	4	44,009
aids 组	124	7	39,581

同一 Luna 模型、同一公开集。官方为冻结快照，工具与上下文管理不同； trace 组沿用历史两阶段协议， aids 组从第 1 关按整局 2,000 动作运行。差值是整体配置效果；五游戏同预算三轮对照 12.7 → 33.4 ， 15 对中 13 对提高。

Trace：是什么、存什么、怎么存、怎么用

是什么	一次运行的 span 树：父子关系、起止时间、状态与类型，读取时组装为调用树和时间轴
存什么	按 GenAI 约定：结构与时间字段必有，属性与度量可选，消息与工具内容体积大、默认不采集
怎么存	动态属性按访问需求选 JSON 文本或结构化表示；长载荷按引擎选同表、列表副本或外置
怎么用	运行中读回历史、断点恢复、整理成经验提示；事后用于评估、数据准备与失败归因

谢谢

欢迎提问与交流

下一位分享：基于执行证据的失败归因分析

曹金羽 · Agent Trace 组